

UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY

VIZUÁLNY TRANSFORMER SO SEKUNDÁRYM
VYNORENÍM
DIPLOMOVÁ PRÁCA

2027

BC. MATEJ MIŠKOVČÍK

UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY

VIZUÁLNY TRANSFORMER SO SEKUNDÁRYM
VYNORENÍM
DIPLOMOVÁ PRÁCA

Študijný program: Aplikovaná informatika
Študijný odbor: Informatika
Školiace pracovisko: Katedra aplikovanej informatiky
Školiteľ: RNDr. Andrej Lúčny, PhD.

Bratislava, 2027
Bc. Matej Miškovčík



ZADANIE ZÁVEREČNEJ PRÁCE

Meno a priezvisko študenta: Bc. Matej Miškovčík
Študijný program: aplikovaná informatika (Jednoodborové štúdium, magisterský II. st., denná forma)
Študijný odbor: informatika
Typ záverečnej práce: diplomová
Jazyk záverečnej práce: slovenský
Sekundárny jazyk: anglický

Názov: Vizuálny transformer so sekundárnym vynorením
Vision transformer with the secondary wipe-out

Anotácia: Práca má kompilačno-implementačný charakter a zaoberá sa nahradením klasického vynorenia vo vizuálnych transformeroch experimentálnym. Vizuálny transformer slúži na klasifikáciu obrazu a jeho výstupom sú pravdepodobnosti príslušnosti obrazu k uvažovaným kategóriám. Zakončený býva buď vynorením, kedy sa výstupný CLS token porovnáva s vektormi reprezentujúcimi jednotlivé kategórie, alebo hlavou, kedy z CLS tokenu počíta perceptron logaritmy pravdepodobností. Cieľom práce je vyskúšať vynorenie, v ktorom môžu byť kategórie reprezentované viacerými vektormi.

Cieľ:

1. Naštudovať a v práci podrobne a čitateľa obohacujúco opísať ako funguje vizuálny transformer (model ViT)
2. Natrénovať ViT s klasickým vynorením a klasickou hlavou
3. Navrhnuť experimentálne vynorenie, v ktorom je kategória reprezentovaná viacerými vektormi
4. Porovnať tieto tri riešenia

Literatúra: Stefania Cristina and Mehreen Saeed: Building Transformer Models with Attention, 2022 MachineLearningMastery.com
Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., & Houlsby, N. (2021). An image is worth 16×16 words: Transformers for image recognition at scale. In Proceedings of the 9th International Conference on Learning Representations (ICLR 2021). <https://arxiv.org/abs/2010.11929>

Poznámka: Python, pytorch

Kľúčové slová: Vizuálny transformer, vynorenie, klasifikácia obrazu

Vedúci: RNDr. Andrej Lúčny, PhD.
Katedra: FMFI.KAI - Katedra aplikovanej informatiky
Vedúci katedry: doc. RNDr. Tatiana Jajcayová, PhD.
Dátum zadania: 29.10.2025

Dátum schválenia: 11.11.2025

prof. RNDr. Roman Ďurikovič, PhD.
garant študijného programu



Univerzita Komenského v Bratislave
Fakulta matematiky, fyziky a informatiky

.....
š t u d e n t

.....
v e d ú c i p r á c e

Čestné prehlásenie

Čestne vyhlasujem, že dimplovú bakalársku prácu na tému **Vizuálny transformer so sekundárom vynorením**, vrátane všetkých jej príloh a obrázkov, som vypracoval samostatne, a to s použitím literatúry uvedenej v priloženom zozname a nástrojov umelej inteligencie. Vyhlasujem, že nástroje umelej inteligencie som použil v súlade s príslušnými právnymi predpismi, akademickými právami a slobodami, etickými a morálnymi zásadami za súčasného dodržania akademickej integrity a že ich použitie je v práci vhodným spôsobom označené.

V Bratislave, dňa x.x.202x

.....
Matej Miškovčík

Pod'akovanie

Chcel by som sa pod'akovať môjmu vedúcemu práce ...

Abstrakt

Cieľom tejto diplomovej práce je ...

Kľúčové slová: Vizualný transformér, vynorenie

Abstract

The aim of this dimploma thesis ...

Keywords: Vision Transformer, wipeout

Obsah

Úvod	1
1 Východiská práce	3
1.1 Neurónové siete	3
1.2 Hlboké učenie	3
1.3 Transformer architektúra	3
1.4 Self-attention mechanizmus	3
2 Vision Transformery	5
2.1 Reprezentácia obrazu pomocou patchov	5
2.2 Patch embedding	5
2.3 CLS token	5
2.4 Pozicionálne embeddingy	5
2.5 Architektúra Vision Transformeru	5
2.6 Klasifikácia obrazu vo Vision Transformeroch	5
3 Klasifikačné mechanizmy vo Vision Transformeroch	7
3.1 Klasický MLP head	7
3.2 Klasifikácia založená na podobnosti embeddingov	7
3.3 Vynorenie kategórií	7
3.4 Jednovektorová reprezentácia tried	7
4 Viacvektorové vynorenie kategórií	9
4.1 Motivácia viacvektorového prístupu	9
4.2 Variabilita objektov v rámci tried	9
4.3 Návrh viacvektorovej reprezentácie	9
4.4 Porovnávanie CLS tokenu s reprezentáciami tried	9
4.5 Výhody a obmedzenia navrhnutého prístupu	9
5 Implementácia	11
5.1 Použité technológie	11
5.2 Vývojové prostredie	11

5.3	Implementácia baseline modelu	11
5.4	Implementácia klasického MLP head	11
5.5	Implementácia modelu založeného na vynorení	11
5.6	Implementácia viacvektorového modelu	11
6	Experimenty a vyhodnotenie	13
6.1	Použité datasety	13
6.2	Nastavenie experimentov	13
6.3	Vyhodnocovacie metriky	13
6.4	Výsledky baseline modelu	13
6.5	Výsledky modelu založeného na vynorení	13
6.6	Výsledky viacvektorového modelu	13
6.7	Diskusia výsledkov	13
	Záver	15

Zoznam obrázkov

Zoznam tabuliek

Úvod

V posledných rokoch zaznamenali metódy hlbokého učenia výrazný pokrok v oblasti spracovania obrazu a počítačového videnia. Medzi najvýznamnejšie architektúry patria konvolučné neurónové siete, ktoré boli dlhodobo dominantným prístupom pri úlohách klasifikácie obrazu. S rozvojom transformer architektúr, pôvodne navrhnutých pre spracovanie prirodzeného jazyka, sa však začali objavovať aj nové prístupy založené na mechanizme self-attention.

Jedným z takýchto prístupov sú Vision Transformer (ViT), ktoré aplikujú transformer architektúru na úlohy spracovania obrazu. Namiesto klasických konvolučných operácií rozdeľujú vstupný obraz na menšie časti nazývané patch-e, ktoré následne spracovávajú podobným spôsobom ako tokeny v jazykových modeloch. Významnou súčasťou Vision Transformerov je tzv. CLS token, ktorý reprezentuje globálnu informáciu o celom obraze a slúži ako vstup pre následnú klasifikáciu.

Štandardne býva klasifikácia vo Vision Transformeroch realizovaná pomocou klasifikačnej hlavy, ktorá z CLS tokenu vypočítava pravdepodobnosti jednotlivých tried. Okrem klasického prístupu však existujú aj alternatívne metódy založené na porovnávaní výstupného embeddingu s reprezentáciami jednotlivých kategórií. Takýto prístup je v tejto práci označovaný ako vynorenie.

Diplomová práca sa zameriava na experimentálne preskúmanie klasifikácie založenej na vynorení vo Vision Transformeroch. Hlavnou myšlienkou je skúmať možnosť reprezentácie jednej kategórie viacerými vektormi namiesto jediného prototypu triedy. Predpokladom je, že viacvektorová reprezentácia môže lepšie zachytiť variabilitu objektov v rámci jednej kategórie a umožniť flexibilnejšie porovnávanie výstupných reprezentácií modelu.

Cieľom práce bude analyzovať existujúce klasifikačné mechanizmy vo Vision Transformeroch, implementovať experimentálne prístupy založené na vynorení a následne ich porovnať s klasickým MLP head prístupom pomocou vybraných metrík klasifikácie obrazu.

Kapitola 1

Východiská práce

[2] ... [1]

1.1 Neurónové siete

1.2 Hlboké učenie

1.3 Transformer architektúra

1.4 Self-attention mechanizmus

Kapitola 2

Vision Transformery

2.1 Reprezentácia obrazu pomocou patchov

2.2 Patch embedding

2.3 CLS token

2.4 Pozicionálne embeddingy

2.5 Architektúra Vision Transformeru

2.6 Klasifikácia obrazu vo Vision Transformeroch

Kapitola 3

Klasifikačné mechanizmy vo Vision Transformeroch

3.1 Klasický MLP head

3.2 Klasifikácia založená na podobnosti embeddingov

3.3 Vynorenie kategórií

3.4 Jednovektorová reprezentácia tried

Kapitola 4

Viacvektorové vynorenie kategórií

- 4.1 Motivácia viacvektorového prístupu
- 4.2 Variabilita objektov v rámci tried
- 4.3 Návrh viacvektorovej reprezentácie
- 4.4 Porovnávanie CLS tokenu s reprezentáciami tried
- 4.5 Výhody a obmedzenia navrhnutého prístupu

Kapitola 5

Implementácia

5.1 Použité technológie

5.2 Vývojové prostredie

5.3 Implementácia baseline modelu

5.4 Implementácia klasického MLP head

5.5 Implementácia modelu založeného na vynorení

5.6 Implementácia viacvektorového modelu

Kapitola 6

Experimenty a vyhodnotenie

6.1 Použité datasety

6.2 Nastavenie experimentov

6.3 Vyhodnocovacie metriky

6.4 Výsledky baseline modelu

6.5 Výsledky modelu založeného na vynorení

6.6 Výsledky viacvektorového modelu

6.7 Diskusia výsledkov

Záver

...

Literatúra

- [1] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations*, 2021.
- [2] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in neural information processing systems*, pages 5998–6008, 2017.