

Vizuálny transformer so sekundárnym vynorením

Bc. Matej Miškovčík
FMFI UK


Školiteľ: RNDr. Andrej Lúčny, PhD.

2026

Motivácia práce

- Vizuálny transformer patrí medzi moderné modely pre klasifikáciu obrazu
- Zakončený môže byť:
 - Vynorením – výstup (CLS token) sa porovnáva s vektormi kategórií
 - Hlavou – perceptron z CLS tokenu počíta logaritmy pravdepodobností
- Pri klasickom vynorení je kategória reprezentovaná jedným vektorom
- Práca skúma rozšírenie: kategória reprezentovaná viacerými vektormi
- Cieľom je overiť, či viacvektorová reprezentácia lepšie zachytí variabilitu objektov v triede

Architektúra Vision Transformeru



Zdroj: Dosovitskiy et al., 2021

- obraz sa rozdelí na patch-e
- patch-e sa prevedú na embeddingy
- transformer encoder spracúva sekvenciu tokenov
 - encoder sa skladá z N identických vrstiev
 - každá vrstva obsahuje :
 - **Multi-Head Self-Attention**
 - **Feed Forward Network**
 - residual connection a **LayerNorm** po každom attention a FFN bloku

$$\text{LayerNorm}(x + \text{Sublayer}(x))$$

- Výstupný **CLS token** reprezentuje celý obraz

Vynorenie

- CLS token reprezentuje celý obraz
- klasifikácia založená na podobnosti vektorov
- CLS token sa porovnáva s reprezentáciami kategórií
- výsledná trieda má najvyššiu cosine similarity

$$\cos(z_{CLS}, c_i)$$

z_{CLS} = reprezentácia obrazu

c_i = vektor kategórie

Hlava

- vstupom je výstupný CLS token
- perceptron počíta skóre pre každú kategóriu
- tieto skóre interpretujeme ako logity
- softmax prevedie logity na pravdepodobnosti tried

Experiment: viacvektorové vynorenie kategórií

1 kategória $\rightarrow$ k vektorov namiesto jedného

- cieľom je rozšíriť klasické vynorenie kategórií
- jedna trieda nebude reprezentovaná jedným vektorom, ale množinou vektorov
- každý vektor môže zachytávať inú podobu objektu v danej kategórii

Aktuálny stav práce

- založený GitHub repozitár
- vytvorená LaTeX kostra diplomovej práce
- preštudovaná základná literatúra
- pripravené vývojové prostredie
- otestovaný framework/knižnice

Github + LaTeX

Štruktúra repozitára

```
.  
├ docs/           # diplomová práca, literatúra, PDF a .bib súbor  
├ experiments/    # experimenty a notebooky  
├ src/            # implementácia modelov  
├ data/           # datasety  
├ results/        # výsledky experimentov  
└ README.md
```

V README.md sa nachádzajú aj ciele a plánované úlohy

Literatúra

Attention is All You Need – *Vaswani et al., 2017*

- predstavili architektúru **Transformer**
- nahradili rekurentné vrstvy mechanizmom **self-attention**
- zaviedli **multi-head attention**
- encoder a decoder sú tvorené opakovaním rovnakých vrstiev
- model dosiahol veľmi dobré výsledky v strojovom preklade

An Image is Worth 16x16 Words: Transformers For Image Recognition At Scale – Dosovitskiy et al., 2021

- aplikovali Transformer na klasifikáciu obrazu
- obraz rozdelili na malé **patch-e**
- patch-e spracovali ako sekvenciu tokenov
- dosiahli konkurencieschopné výsledky bez použitia CNN vrstiev

Framework test

V mojom teste je použitý predtrénovaný Vision Transformer vit_b_16 z knižnice torchvision. Cieľom je overiť načítanie modelu, predspracovanie vstupného obrázka a získanie výstupných pravdepodobností tried.



```
golden retriever: 0.8354  
Labrador retriever: 0.0116  
kuvasz: 0.0057  
tennis ball: 0.0031  
Great Pyrenees: 0.0019
```

Plán ďalšej práce

- implementácia ViT s klasickým vynorením
- implementácia ViT s hlavou
- implementácia ViT s viacvektorovým vynorením
- návrh experimentov
- vyhodnotenie výsledkov

Ďakujem za pozornosť

Github link: <https://github.com/BushDemon/ViT-prototype-classification>