

Vizuální transformer so sekundárnym vynorením


Bc. Matej Miškovčík
FMFI UK

Motivácia práce

- Vision Transformery patria medzi moderné modely pre klasifikáciu obrazu
- Klasifikácia sa štandardne realizuje pomocou MLP head prístupu
- Existujú aj alternatívne prístupy založené na porovnávaní embeddingov
- Práca skúma možnosť reprezentácie kategórií viacerými vektormi

Architektúra Vision Transformeru

- obraz sa rozdelí na patch-e
- patch-e sa prevedú na embeddingy
- transformer encoder spracúva sekvenciu tokenov
- CLS token reprezentuje celý obraz



Prístupy ku klasifikácii

KLASICKÝ MLP HEAD

CLS token $\rightarrow$ MLP head $\rightarrow$ logits $\rightarrow$ softmax

- štandardný prístup vo Vision Transformeroch
- perceptron vypočítava skóre tried
- výstupom sú pravdepodobnosti kategórií

VYNORENIE

CLS token $\leftrightarrow$ reprezentácie kategórií

- klasifikácia založená na podobnosti embeddingov
- CLS token sa porovnáva s reprezentáciami tried
- alternatíva ku klasickému classification head prístupu

Viacvektorové vynorenie kategórií

1 kategória → viac reprezentujúcich vektorov

- jedna trieda nemusí byť reprezentovaná jediným prototypom
- objekty jednej kategórie môžu mať vysokú variabilitu
- viacvektorová reprezentácia môže lepšie zachytiť rôzne podoby objektov

Aktuálny stav práce

- založený GitHub repozitár
<https://github.com/BushDemon/ViT-prototype-classification>
- vytvorená LaTeX kostra diplomovej práce
- pripravené vývojové prostredie
- otestovaný framework/knižnice
- preštudovaná základná literatúra

Github + LaTeX

Štruktúra repozitára

```
.
├── docs/           # diplomová práca, literatúra, PDF a .bib súbor
├── experiments/    # experimenty a notebooky
├── src/            # implementácia modelov
├── data/           # datasety
├── results/        # výsledky experimentov
└── README.md
```

V README.md sa nachádzajú aj ciele a plánované úlohy

Framework test

V mojom teste je použitý predtrénovaný Vision Transformer vit_b_16 z knižnice torchvision. Cieľom je overiť načítanie modelu, predspracovanie vstupného obrázka a získanie výstupných pravdepodobností tried.



```
golden retriever: 0.8354  
Labrador retriever: 0.0116  
kuvasz: 0.0057  
tennis ball: 0.0031  
Great Pyrenees: 0.0019
```


Plán ďalšej práce

- implementácia klasifikácie založenej na vynorení
- implementácia viacvektorového modelu
- návrh experimentov
- porovnanie s baseline modelom
- vyhodnotenie výsledkov

Ďakujem za pozornosť
